

Análise do Crescimento Urbano no Litoral de Santa Catarina via Imagens de Luzes Noturnas

Equipe: Felipe Giovanella, Gustavo Campestrini e Nicolas Ceruti

Resumo. O trabalho investiga onde e como as áreas urbanas do litoral de Santa Catarina cresceram entre 2015 e 2025, usando luzes noturnas (NTL) do produto VIIRS Black Marble (VNP46A2). O pipeline combina pré-processamento de rasters, uma rede ConvLSTM2D que classifica o padrão temporal de brilho de cada região ao longo dos anos e análise geoespacial. Como produto final calcula-se o IPA (Índice de Prioridade de Acesso), que mede o quanto o crescimento de cada município se concentra próximo à BR-101. Avaliado em uma região de teste geograficamente separada, o modelo alcançou acurácia de 0,85 e F1-macro de 0,70. Dos 38 municípios litorâneos, 18 concentram o crescimento até 5 km da rodovia, o que orienta a recomendação de priorizar acesso viário (IPA alto) ou mobilidade urbana interna (IPA baixo).

1. Problema e objetivo

O monitoramento do crescimento urbano costuma depender de censos pouco frequentes. As imagens de luzes noturnas oferecem alternativa de baixo custo e cobertura contínua: o brilho artificial é um indicador consolidado de atividade humana e expansão urbana. O litoral catarinense, de rápido adensamento por turismo, porto e pelo eixo da BR-101, é o objeto de estudo.

A pergunta central é: *onde e como o litoral de SC cresceu na última década?* Como desdobramento, relaciona-se a expansão urbana à mobilidade regional: municípios que crescem colados à rodovia tendem a demandar acesso viário, enquanto os que crescem em áreas periféricas demandam mobilidade urbana interna. O trabalho articula pré-processamento de imagens, classificação por aprendizado profundo (TensorFlow/Keras e scikit-learn) e visualização/análise espacial.

2. Base de dados e pré-processamento

Dados. Composições mensais do produto VIIRS Black Marble (VNP46A2), de 2015 a 2025 (11 anos), com 48 GeoTIFFs por ano (múltiplos tiles $\times$ 12 meses); valor inválido 65535 e fator de escala 0,1 (unidade $\text{nW}\cdot\text{cm}^{-2}\cdot\text{sr}^{-1}$). A área de estudo vem do shapefile do IBGE (SC_Municípios_2024, 295 municípios), do qual se filtraram os 38 do litoral. O traçado da BR-101 foi obtido do OpenStreetMap (Geofabrik), com 2.643 segmentos em SC.

Pré-processamento (rasterio/geopandas). Para cada ano: reprojeção para EPSG:31982 (UTM 22S), mosaico dos tiles e recorte pela área de estudo, marcação de valores inválidos como NaN (filtro de qualidade) e mediana anual dos 12 meses, suprimindo nuvens e ruído. A normalização usa $\log_{1p}$ seguido de recorte por percentis [0,5–99,5] e reescala para [0,1], aplicada por frame (per-sample) para que um ano muito brilhante não distorça a escala dos demais. A grade final tem 769 $\times$ 293 pixels; os compostos são mantidos em cache.




Figura 1 — Mapa interativo (Folium) com IPA por município e traçado da BR-101.

3. Patches interanuais, rotulagem e divisão dos dados

Cada amostra é uma sequência interanual: para cada posição espacial, empilha-se o mesmo patch de 32×32 pixels ao longo dos 11 compostos anuais, formando um tensor (11, 32, 32). Assim o modelo aprende o padrão de crescimento ao longo da década (alinhado ao IPA), e não a sazonalidade de um único ano. Usou-se passo 16 (50% de sobreposição) e patches com $\geq 70\%$ de pixels válidos em todos os anos, resultando em 682 patches.

A rotulagem é automática pela razão entre o brilho médio dos 2 últimos e dos 2 primeiros anos. Patches sem luz (abaixo de 0,005 nos dois extremos) recebem BAIXO; entre os 124 patches com brilho real, os limiares são definidos por percentis (P33 e P67) — neste run, BAIXO < 1,61, MÉDIO até 1,91 e ALTO $\geq 1,91$:

Classe	Critério	Patches	Proporção
BAIXO	sem luz ou razão < P33	599	87,8%
MÉDIO	$P33 \leq \text{razão} < P67$	42	6,2%
ALTO	razão $\geq P67$	41	6,0%

Tabela 1 — Distribuição dos 682 patches. O predomínio de BAIXO decorre da grande área escura (sem luz) do litoral.

Divisão espacial (sem vazamento de dados). Como patches vizinhos se sobrepõem, um split aleatório vazaria informação entre treino e teste. Por isso a divisão é geográfica, pela linha do raster: terço norte-centro → treino (448 patches), terço central → validação (115) e terço sul → teste (119). O modelo nunca vê pixels da região de teste durante o treinamento.

4. Modelo ConvLSTM2D, balanceamento e treinamento

Adotou-se uma rede ConvLSTM2D — variante da LSTM cujas operações internas são convoluções, aprendendo padrão espacial e evolução temporal de forma conjunta. Para conter o desbalanceamento, o treino combina oversample das classes minoritárias (408

amostras por classe), pesos de classe {BAIXO 1; MÉDIO 5; ALTO 4}, um modelo enxuto com Dropout 0,6 e um callback que seleciona os pesos de melhor F1-macro na validação.

Camada	Saída	Parâmetros
Input	(11, 32, 32, 1)	0
ConvLSTM2D 16 (3×3), tanh, return_seq	(11, 32, 32, 16)	9.856
BatchNormalization	(11, 32, 32, 16)	64
ConvLSTM2D 32 (3×3), tanh	(32, 32, 32)	55.424
BatchNormalization → GlobalAvgPool2D	(32)	128
Dense 32 ReLU → Dropout 0,6	(32)	1.056
Dense 3, Softmax	(3)	99

Tabela 2 — Arquitetura (66.627 parâmetros). Otimizador Adam 1e-3, perda sparse categorical crossentropy, até 80 épocas, batch 32.

5. Avaliação do modelo (testes)

Avaliado no conjunto de teste (terço sul, nunca visto no treino), o modelo obteve acurácia de 0,85 e F1-macro de 0,70. A Tabela 3 traz as métricas por classe e a Figura 2, as curvas de aprendizado (Figura 2).

Classe	Precisão	Revocação	F1	Suporte
BAIXO	1,00	0,88	0,94	94
MÉDIO	0,57	0,75	0,65	16
ALTO	0,40	0,67	0,50	9
Média macro	0,66	0,77	0,70	119

Tabela 3 — Métricas por classe no teste. Acurácia global 0,85; F1-macro 0,70.




Figura 2 — Curvas de loss e de acurácia/F1-macro durante o treinamento.

As estratégias de balanceamento foram decisivas para recuperar as classes minoritárias: MÉDIO e ALTO, antes ignoradas em favor de BAIXO, passaram a ser detectadas (revocação 0,75 e 0,56). O F1-macro de 0,70 e os baixos suportes de teste (16 e 9 amostras) indicam que essas classes ainda têm desempenho instável — limitação discutida na Seção 8.

6. Produtos cartográficos

O mapa de diferença relativa $(\text{brilho}_{2025} - \text{brilho}_{2015})/(\text{brilho}_{2015} + 0,01)$, com clip dinâmico pelos percentis P2–P98 $([-0,07; 3,63])$ para suprimir outliers (ex.: Imaruí), destaca ganho (vermelho) e perda (azul) de brilho (Figura 2). O centróide de brilho por município indica a direção do adensamento — maiores deslocamentos em Itapoá (1,23 km), Paulo Lopes (1,20 km) e B. Barra do Sul (1,14 km).




Figura 2 — Diferença relativa de brilho 2025 - 2015 (clip P2-P98). Vermelho = crescimento, azul = declínio.

7. IPA — resultados e discussão

O IPA estratifica o crescimento (parcela positiva da diferença) em faixas de distância da BR-101 (0-2, 2-5, 5-10 e >10 km, por buffers em EPSG:32722) e é dado por $IPA = (0-2 \text{ km} + 2-5 \text{ km}) / \text{total}$. Classifica-se cada município em Eixo BR-101 ($\geq 0,65$), Misto (0,35-0,65) ou Periférico ($< 0,35$). Dos 38 municípios: 18 Eixo BR-101 (47%), 11 Misto (29%) e 9 Periférico (24%). A categoria orienta a recomendação: IPA alto sugere priorizar acesso à rodovia; IPA baixo indica crescimento afastado da BR-101 e maior necessidade de mobilidade urbana interna.

Município	IPA	Categoria	Município	IPA	Categoria
São João do Sul	1,000	Eixo BR-101	Gov. Celso Ramos	0,607	Misto
Balneário Camboriú	1,000	Eixo BR-101	Navegantes	0,567	Misto
Sombrio	1,000	Eixo BR-101	Laguna	0,566	Misto
Santa Rosa do Sul	1,000	Eixo BR-101	Araquari	0,553	Misto
Imbituba	0,996	Eixo BR-101	Içara	0,528	Misto
Pescaria Brava	0,986	Eixo BR-101	Camboriú	0,447	Misto
São José	0,966	Eixo BR-101	Jaguaruna	0,417	Misto
Palhoça	0,893	Eixo BR-101	Joinville	0,413	Misto
Itapema	0,882	Eixo BR-101	Tijucas	0,370	Misto
Biguaçu	0,861	Eixo BR-101	Itajaí	0,364	Misto
Porto Belo	0,855	Eixo BR-101	Balneário Gaivota	0,259	Periférico
Imaruí	0,838	Eixo BR-101	Bombinhas	0,156	Periférico
Barra Velha	0,831	Eixo BR-101	Balneário Rincão	0,044	Periférico
Penha	0,829	Eixo BR-101	Florianópolis	0,029	Periférico
Balneário Piçarras	0,722	Eixo BR-101	B. Arroio do Silva	0,025	Periférico
Garopaba	0,710	Eixo BR-101	B. Barra do Sul	0,007	Periférico
Paulo Lopes	0,671	Eixo BR-101	Garuva	0,000	Periférico
Araranguá	0,664	Eixo BR-101	Itapoá	0,000	Periférico
Passo de Torres	0,620	Misto	São Francisco do Sul	0,000	Periférico

Tabela 4 — IPA e categoria por município (ordem decrescente de IPA).




Figura 4 — IPA por município; linhas tracejadas: limiares 0,35 e 0,65.

A leitura é coerente com a geografia. O grupo Eixo reúne a porção continental da Grande Florianópolis — São José (0,966) e Palhoça (0,893) — além de Balneário Camboriú (1,000) e Itapema (0,882). O caso mais ilustrativo do grupo Periférico é Florianópolis (0,029): por ser insular, cresce dentro da ilha, longe do traçado continental da BR-101; padrão semelhante em São Francisco do Sul, Itapoá e Garuva (porto/balneário) e em Bombinhas (orla). O grupo Misto inclui Itajaí (0,364) e Navegantes (0,567), onde o complexo portuário concorre com a rodovia, e Joinville (0,413), de malha urbana ampla.

8. Limitações e direções futuras

- **Poucos patches com brilho real (124 de 682):** as classes MÉDIO e ALTO têm suporte de teste baixo (16 e 9), tornando suas métricas instáveis. Ampliar a base (passo menor, mais áreas) e usar validação cruzada espacial.
- **Rótulos heurísticos:** derivam da razão de brilho, sem verdade de campo; validar contra MapBiomas/áreas edificadas do IBGE.
- **Saturação/anomalias do VIIRS:** mitigadas pelo clip P2–P98 e por usar só crescimento positivo no IPA, mas ainda presentes em núcleos muito brilhantes.
- **Desempenho a melhorar:** F1-macro de 0,70 indica espaço para evolução nas classes minoritárias (mais dados, outras arquiteturas, ajuste de pesos).

9. Conclusão

O pipeline está completo e executado de ponta a ponta: base de 11 anos montada e pré-processada, classificação por ConvLSTM2D interanual com divisão espacial sem vazamento e balanceamento das classes, inferência pixel a pixel, e cálculo do IPA para os 38 municípios. O modelo atinge acurácia 0,85 e F1-macro 0,70, recuperando as classes MÉDIO e ALTO antes ignoradas. O principal achado é o papel estruturador da BR-101, com cerca de metade dos municípios concentrando crescimento até 5 km da rodovia — o que se traduz, por município, em priorizar acesso viário (IPA alto) ou mobilidade urbana interna (IPA baixo).

Referências

- ABADI, M. et al. TensorFlow: large-scale machine learning on heterogeneous systems. 2015. Disponível em: <https://www.tensorflow.org>. Acesso em: jun. 2026.
- INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). Malha municipal de Santa Catarina 2024. Rio de Janeiro: IBGE, 2024. Disponível em: <https://www.ibge.gov.br/geociencias/organizacao-do-territorio/malhas-territoriais>. Acesso em: jun. 2026.
- OPENSTREETMAP CONTRIBUTORS. Extrato de rodovias do Brasil Sul (sul-latest). Geofabrik, 2025. Disponível em: <https://download.geofabrik.de/south-america/brazil/sul.html>. Acesso em: mai. 2026.
- PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.
- ROMÁN, M. O. et al. NASA's Black Marble nighttime lights product suite. *Remote Sensing of Environment*, v. 210, p. 113–143, 2018.
- SHI, X. et al. Convolutional LSTM network: a machine learning approach for precipitation nowcasting. In: *ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NeurIPS)*, 2015. p. 802–810.